



Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Deploy de Modelos

Técnicas e Procedimentos de Deploy de Modelos



Depois de avaliar e otimizar o modelo, se você estiver satisfeito com sua versão final, é hora de colocá-lo em produção — fazer o deploy. Abaixo estão algumas técnicas e procedimentos fundamentais para realizar esse processo com sucesso:

1. Flexibilidade no Deploy do Modelo:

Não existe uma única forma de fazer o deploy de um modelo de Machine Learning. O método utilizado vai depender do objetivo do projeto. Podemos executar o modelo localmente, via linha de comando, ou integrá-lo a uma aplicação web ou móvel, como um aplicativo para smartphones. O objetivo do projeto deve sempre guiar a escolha da melhor forma de deploy.

2. Planejamento do Deploy desde o Início:

É importante que, no início do projeto, já se tenha uma noção de como o modelo será entregue em produção. O Cientista de Dados geralmente finaliza seu trabalho ao entregar o modelo pronto, otimizado e validado. A partir desse ponto, a responsabilidade do deploy e da manutenção do modelo é passada para um Engenheiro de Machine Learning, que cuidará dos aspectos técnicos do lançamento e atualização do modelo.

3. Consistência nas Transformações de Dados:

Um aspecto que deve ser considerado no deploy é garantir que as mesmas transformações aplicadas aos dados de treino sejam aplicadas aos dados novos usados em produção. Por exemplo, se o modelo foi treinado com dados normalizados, os novos dados devem ser normalizados da mesma forma antes de serem usados pelo modelo. Qualquer incoerência nas transformações pode comprometer a acurácia do modelo.



4. Consistência nas Variáveis do Modelo:

O modelo só poderá fazer previsões se os novos dados contiverem o mesmo número de variáveis que foram usadas durante o treinamento. Se o modelo foi treinado com quatro variáveis, por exemplo, ele não funcionará corretamente com dados que tenham menos ou mais variáveis. Portanto, é fundamental garantir que o pré-processamento e a Engenharia de Atributos sigam os mesmos padrões.

5. Implementação de MLOps:

Para garantir a escalabilidade e a manutenção eficiente de modelos em produção, as empresas devem implementar práticas de MLOps (Machine Learning Operations). MLOps envolve o versionamento dos modelos, re-treinamento frequente com novos dados e monitoramento contínuo do desempenho. Um Engenheiro de Machine Learning geralmente é responsável por essas atividades.

6. Ferramentas de Deploy em Nuvem:


Ferramentas de Machine Learning em nuvem, como o AWS SageMaker, facilitam o deploy de modelos. Elas permitem criar APIs que possibilitam a chamada do modelo a partir de novos dados para gerar previsões em tempo real. Essas soluções oferecem infraestrutura pronta e escalável, tornando o processo de deploy mais eficiente.

7. Múltiplos Modelos em Produção:

Cada modelo de Machine Learning é projetado para resolver um problema específico. Portanto, é comum que várias soluções diferentes estejam em produção simultaneamente, cada uma com um propósito distinto. O controle de versão e o gerenciamento de múltiplos modelos tornam-se, assim, uma parte crítica da infraestrutura de produção.

8. Automatização com Pipelines de Dados:

Como os modelos em produção serão continuamente alimentados com novos dados, é essencial criar pipelines de dados automatizados. Um pipeline de dados eficiente extrai informações da fonte, aplica todas as transformações necessárias (conforme realizado durante o treino do modelo) e as direciona para o modelo em produção, funcionando como uma linha de produção para previsões.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.