




DSAKG®

Guia de Conhecimentos em Ciência de Dados da Data Science Academy



Bem-Vindo(a)





ACADEMY, D.S. *E-book. Guia de Conhecimentos e Boas Práticas em Ciência de Dados da Data Science Academy.*
Brasília, 2024.

Versão 1.0.3

Copyright © 2024 Data Science Academy
Todos os direitos reservados.



www.datascienceacademy.com.br

Data Science Academy



Nossa maior satisfação é ver nossos alunos progredirem, com autonomia, inovação, criatividade e dinamismo, incorporando sempre novos conhecimentos, promovendo seu crescimento profissional e pessoal.

Nosso objetivo é que você aprenda de verdade e seja reconhecido no mercado de trabalho. Por isso, mais uma vez, a DSA avança na expansão e promoção do conhecimento, trazendo de forma pioneira um Programa Completo de **Certificação em Ciência de Dados** para várias carreiras e diferentes níveis.


Elaboramos um guia versátil, completo e inovador, que fará de você um profissional diferenciado e altamente recomendado para o mercado de Trabalho.

Onde quer que você esteja em sua jornada de aprendizagem, nós esperamos que você esteja sempre crescendo e renovando suas habilidades. **Siga em frente!**





Índice



Introdução


A Ciência de Dados já é uma realidade no Brasil. As empresas que não criarem uma cultura data-driven e incluírem a análise de dados em suas estratégias corporativas se tornarão irrelevantes. E gestores atentos estão criando e desenvolvendo suas equipes de Data Science. É um caminho sem volta, pois o volume de dados não vai parar de crescer e quem souber extrair valor dos dados estará a frente dos concorrentes. Em pouco tempo isso será requisito básico.

Com o aumento da demanda, estima-se que não haverá profissionais qualificados em número suficiente ainda por um bom tempo. Além disso, a Ciência de Dados veio para ficar. Pensando nisso, a DSA criou esse Guia de Boas Práticas em Ciência de Dados chamado **DSAKG**.

O **DSAKG** é um livro contendo as boas práticas em Ciência de Dados, resultado do trabalho dos profissionais da DSA e experiência capacitando mais de 900 mil alunos ao longo de mais de 8 anos.

Convidamos você a iniciar uma excelente jornada de aprendizagem durante a leitura desse extraordinário material.

Unidade I





Por que Aprender Ciência de Dados?





Habilidades em Ciência de Dados podem ajudar você a ser mais competitivo no mercado de trabalho.

De um modo geral, a Ciência de Dados oferece um conjunto de habilidades que podem ser aplicadas na solução de problemas de negócios em empresas de qualquer setor, desde que a matéria-prima esteja disponível: dados.

Neste guia, vamos apresentar os fundamentos da Ciência de Dados que você precisa ter conhecimento para alavancar sua carreira. E vamos fornecer um plano para você desenvolver essas competências e colocá-las em prática. Venha Conosco!





O que você pode fazer com a Ciência de Dados de acordo com a sua carreira?

Como um Cientista de Dados



Você pode extrair insights para fornecer resultados impactantes e baseados em evidências a fim de suportar a tomada de decisões.

Como um Engenheiro de Dados

Você pode empregar técnicas de processamento em larga escala para construir sistemas de armazenamento e pipelines de dados.



Como um Estatístico



Você pode aplicar técnicas de programação e processamento de dados para realizar análises estatísticas.

Como um Analista de Dados

Você pode obter conhecimento a partir dos dados e ser o interlocutor entre os aspectos técnicos e de negócios.



Como um Estudante



Você pode iniciar sua jornada em Ciência de Dados para fortalecer seu campo de pesquisa ou iniciar uma carreira especializada.



Habilidades em Ciência de Dados para o seu Sucesso.



1. Ciclo de Vida da Ciência de Dados

2. Linguagem de Programação

3. Limpar e Manipular Dados

4. Estatística

5. Visualização de Dados

6. Machine Learning

7. Storytelling



1

Ciclo de Vida da Ciência de Dados



Possuir conhecimento básico em como transformar dados e gerar insights é fundamental para o sucesso na sua carreira em Ciência de Dados.

A figura acima representa o processo desde a definição do problema de negócio até o feedback do resultado do seu trabalho de análise.


À medida que você obtém uma compreensão teórica do processo, você precisará ampliar a sua compreensão prática realizando estudos de caso e projetos aplicados ao mundo real.





1

Ciclo de Vida da Ciência de Dados



Conhecimentos em matemática e estatística; conhecimentos em programação (Ciência da Computação) e conhecimento das áreas de negócios são o conjunto de habilidades que combinadas geram um excelente profissional em Ciência de Dados.

Você pode ter uma ou mais dessas habilidade e, com base no seu nível de especialização, desenvolver as demais habilidades.

De fato, você estará em constante evolução. Para trabalhar com Ciência de Dados é preciso ter uma habilidade secreta: gostar de estudar e estar sempre aprendendo.





Em Ciência de Dados estamos sempre trabalhando em projetos.



Ciência de Dados existe para resolver problemas. E cada problema pode requerer diferentes abordagens e ferramentas. Cada problema a ser resolvido será um projeto diferente.



Logo, você estará trabalhando orientado a projetos e cada projeto de Ciência de Dados com um ciclo de vida com começo, meio e fim bem definidos. Terminado um projeto, sorria e siga para o próximo.



Seu trabalho é compreender bem o ciclo de vida de projetos de Ciência de Dados e então aplicar as técnicas de acordo com o problema a ser resolvido, o que vai requerer diferentes ferramentas.





2

Linguagem de Programação



Conhecimento em linguagem de programação é essencial para todos os profissionais de Ciência de Dados. Dito isto, a proficiência exigida pode variar de acordo com as empresas e os cargos.

Se você pretende se tornar um engenheiro, desenvolvedor ou programador de Big Data, espera-se que você tenha habilidade de programação em diferentes linguagens. Python, R e SQL são as linguagens mais populares para Ciência de Dados.

Escolhida a linguagem que vai trabalhar, você deve se familiarizar com as principais bibliotecas que complementarão seu conhecimento de programação e facilitarão sua vida. As bibliotecas fornecem acesso a funções pré-escritas e permitem que você execute tarefas básicas com apenas algumas poucas linhas de código.





2

Linguagem de Programação



Algumas das bibliotecas mais comuns em Python incluem Numpy, pandas, Matplotlib e Scikit-learn. Em R, você pode se beneficiar de pacotes como tidyverse, caret e ggplot2.

Julia, Java e Scala são algumas outras linguagens com as quais as empresas trabalham. Essas linguagens podem apresentar um pouco mais de complexidade e não recomendamos para iniciantes.

Comece sua jornada com uma linguagem mais simples e amigável como Python ou R e então considere aprender linguagens mais avançadas.

Boa parte do que usamos de programação em Ciência de Dados é na verdade linguagem de script, ou seja, uma sequência lógica de operações para resolver um problema. Raramente usamos programação avançada em Ciência de Dados.





2

Linguagem de Programação



Python se tornou a língua franca da Ciência de Dados, capaz de realizar diversas operações de manipulação e análise de dados. Já a Linguagem R é excelente para análise estatística.

Python e R são as linguagens mais escolhidas porque elas:



São Gratuitas e de Código Aberto.



Possuem muitas bibliotecas focadas em dados.




Têm uma grande comunidade de colaboradores.





3

Limpar e Manipular Dados



Os dados recebidos na maioria das vezes não estão prontos para serem utilizados. Ou seja, não estão limpos e organizados .

Os dados chegam em grande volume e geralmente são armazenados em um banco de dados ou Data Lake (local ou em nuvem). Os dados podem estar estruturados, podem estar em um documento de texto ou pode não ter nenhuma estrutura. Esses dados precisam ser limpos e organizados para atender às condições necessárias para inferência e modelagem estatística. Esse processo é conhecido como limpeza de dados.

Cerca de 50 a 80% do tempo dos profissionais de Ciência de Dados é dedicado à preparação de dados para processamento. Isso torna a limpeza e manipulação de dados uma habilidade essencial.

Algumas das técnicas empregadas no processo incluem tratamento de valores ausentes, correção de tipos de dados, identificação e tratamento de outliers, remoção de linhas duplicados, entre outros. Veremos essas técnicas no decorrer deste livro.





4

Estatística



A Ciência de Dados incorpora a era moderna da estatística.

Os profissionais de Ciência de Dados empregam estatística em diversas Etapas do ciclo de vida de projetos de Ciência de Dados, desde interpretar o resultado de uma correlação entre variáveis, até aplicar Otimização Bayesiana de hiperparâmetros.

Uma base em matemática e estatística é muito importante para profissionais de Ciência de Dados.

Você não precisa ser um especialista em matemática, mas deve ter uma base sólida em teoria da probabilidade, álgebra linear e estatística.

Os conceitos de cálculo e teoria computacional podem ser particularmente valiosos se você estiver trabalhando com grandes volumes de dados.





5


Visualização de Dados




A visualização de dados é usada no processamento de dados, pré-processamento, análise, modelagem e apresentação.

Uma boa visualização de dados traduz dados complexos em partes compreensíveis que também podem ser compreendidas por usuários de negócios não técnicos. Algumas das técnicas mais populares de visualização de dados são mostradas abaixo: Histograma, Mapa de Calor, Boxplot e Scatter Plot.


Histograma



Mapa de Calor



Boxplot



Scatter Plot





5

Visualização de Dados



É de suma importância que os profissionais que trabalham com dados sejam altamente proficientes nesta arte, pois o valor real dos dados só pode ser entendido quando a informação for comunicada corretamente.

Você precisará conhecer algumas ferramentas de análise e inteligência além das ferramentas de visualização e espera-se saber trabalhar com linguagem SQL.

Power BI, Tableau, QlikView, Google Data Studio e RapidMiner são algumas ferramentas de análise usadas para se conectar a diferentes fontes de dados e construir gráficos e dashboards.





5

Visualização de Dados



Construir visualizações eficientes é quase uma arte e antes de pensar no gráfico ideal, você deve responder algumas perguntas:

- 1- Qual seu objetivo?
- 2- Qual a sua audiência?
- 3- Que tipo de informação você deseja transmitir (técnica, negócio, acadêmica)?
- 4- Os dados já estão limpos e organizados?
- 5- Quais recursos e ferramentas estão à disposição?
- 6- A informação deve ser transmitida em tempo real?
- 7- Quantas variáveis fazem parte do conjunto de dados e quantas precisamos analisar por vez?
- 8- Precisamos de uma "foto" da informação ou precisamos demonstrá-la ao longo do tempo?
- 9- Um dashboard seria melhor para mostrar diferentes perspectivas dos dados?
- 10- Agora sim, podemos perguntar: qual tipo de gráfico escolher?





5

Visualização de Dados



O conhecimento sobre visualização de dados é capaz de tornar a análise de dados muito mais relevante para as empresas. São muitos os conhecimentos essenciais para que você torne úteis os dados que temos à nossa disposição. Afinal, não adianta repetir que Big Data é importante, se esse oceano de dados disponíveis não for analisado de forma fácil, rápida e útil para as decisões estratégicas do negócio.


Visualização de dados é importante para comunicar a mensagem de forma rápida e eficiente. As informações visuais são processadas 60.000 vezes mais rápido do que texto, e grande parte das informações transmitidas para nosso cérebro no dia a dia são visuais. Além disso, nossa capacidade de absorver e armazenar informações visuais é maior do que em uma simples leitura ou palestra. Você quer ir muito além de fazer um gráfico bonito? Está na hora de criar visualizações que trazem insights.





6

Machine Learning



Machine Learning é um subconjunto da Inteligência Artificial e cresceu muito ao longo dos últimos anos devido a dois fatores: dados em alto volume, variedade e gerados em alta velocidade (Big Data) e Aumento da capacidade computacional.

Machine Learning ajuda a identificar padrões e construir modelos que tomam decisões com o mínimo de intervenção humana. Usamos Machine Learning principalmente para análise preditiva.

Para começar, desenvolva uma compreensão sólida de algoritmos populares, como regressão linear e logística, k-vizinhos mais próximos (KNN), Naive Bayes, Análise de Componentes Principais (PCA) e RandomForest. Então considere algoritmos mais avançadas como redes Neurais artificiais.

Além disso, de acordo com sua função, você pode precisar se especializar em uma área, por exemplo, algoritmos de Processamento de Linguagem Natural (PLN).






7

Storytelling

As 7 áreas do cérebro ativadas pelo storytelling



Não importa se você esteja iniciando sua jornada profissional ou seja um profissional de nível sênior, sempre vale a pena ser bom em comunicação e colaboração.

Várias pesquisas mostram que as habilidades de comunicação e trabalho em equipe são as principais habilidades exigidas em vagas de Ciência de Dados.

Aprimore suas habilidades em comunicação empresarial e pratique o Storytelling, que é a arte de contar histórias usando técnicas inspiradas em roteiristas e escritores para transmitir sua mensagem de forma inesquecível, atraente e cativante.

Você pode ter ideias e mensagens brilhantes para transmitir, mas se não souber como fazer isso da melhor maneira, de nada adianta — sua audiência continuará formada por cadeiras vazias (ou poucos cliques).





Caminhos para Desenvolver suas Habilidades em Ciência de Dados



Habilidades em Ciência de Dados para o seu Sucesso.



1. Faça uma Auto Avaliação
2. Trabalhe em Projetos
3. Faça Cursos Online, Leia Blogs e Livros
4. Obtenha uma Certificação Profissional em Ciência de Dados



1

Faça uma Auto Avaliação



Este é o primeiro passo e acredite, é fundamental.

Você, como profissional, precisa avaliar o momento atual da sua carreira e como pretende estar em 5 ou 10 anos. Se pretende seguir uma carreira em Analytics, seja como Cientista de Dados, Engenheiro de Dados ou Analista, precisa compreender quais são suas habilidades atuais, onde pretende chegar, avaliar os gaps e traçar um plano de ação.

Considere de 6 meses a 1 ano para estar minimamente preparado para atuar no mercado de trabalho. Ajudaremos você com um plano de estudos durante este livro e um roteiro para a auto avaliação.





2

Trabalhe em Projetos




Uma outra forma muito eficaz de aprender Ciência de Dados é trabalhar em projetos. Você pode reproduzir os projetos no seu próprio computador, construir seu portfólio de projetos e desenvolver habilidades de solução de problemas.





3

Faça Cursos Online, Leia Blogs e Livros



A inovação e a disrupção têm impulsionado grande mudança na Ciência de Dados, a aprendizagem ao longo da vida torna-se indispensável para seus praticantes. Mantenha-se atualizado com as últimas notícias e tendências em Ciência de Dados e continue aprendendo.

Você pode aprender o básico e obter um conhecimento aprofundado de habilidades tecnológicas por meio de um meio de autoaprendizagem adequado às suas necessidades. Existem cursos, blogs, livros, vídeos, tutoriais e newsletters que podem fornecer a base necessária para você aprender Ciência de Dados.

Tenha em mente que o aprendizado ocorre ao longo do tempo e através de repetição. Quanto mais estiver envolvido com a Ciência de Dados, mais fácil será seu aprendizado.



4

Obtenha uma Certificação Profissional em Ciência de Dados



À medida que você aprende Ciência de Dados, deve validar seu conhecimento por meio de uma autoridade competente que possa certificar suas habilidades como profissional.

A lacuna de oferta e demanda é enorme no setor de Ciência de Dados e, para profissionais com as habilidades, qualificações, treinamento e experiência certas, conseguir um emprego desejado em Ciência de Dados é uma questão de planejamento.

Ao obter uma certificação profissional em Ciência de Dados, oferecida pela Data Science Academy, você terá credibilidade no mercado de trabalho, credenciado por uma empresa que é referência em Ciência de Dados.

Ter uma certificação profissional prova aos empregadores que você tem as habilidades e o treinamento nas ferramentas e tecnologias de Ciência de Dados necessárias para um desempenho eficiente da função.



Fim da Unidade I