




DSAKG®

Guia de Conhecimentos em Ciência de Dados da Data Science Academy



Bem-Vindo(a)





ACADEMY, D.S. *E-book. Guia de Conhecimentos e Boas Práticas em Ciência de Dados da Data Science Academy.*
Brasília, 2024.

Versão 1.0.3

Copyright © 2024 Data Science Academy
Todos os direitos reservados.



www.datascienceacademy.com.br

Data Science Academy



Nossa maior satisfação é ver nossos alunos progredirem, com autonomia, inovação, criatividade e dinamismo, incorporando sempre novos conhecimentos, promovendo seu crescimento profissional e pessoal.


Nosso objetivo é que você aprenda de verdade e seja reconhecido no mercado de trabalho. Por isso, mais uma vez, a DSA avança na expansão e promoção do conhecimento, trazendo de forma pioneira um Programa Completo de **Certificação em Ciência de Dados** para várias carreiras e diferentes níveis.

Elaboramos um guia versátil, completo e inovador, que fará de você um profissional diferenciado e altamente recomendado para o mercado de Trabalho.

Onde quer que você esteja em sua jornada de aprendizagem, nós esperamos que você esteja sempre crescendo e renovando suas habilidades. **Siga em frente!**



Índice



Introdução


A Ciência de Dados já é uma realidade no Brasil. As empresas que não criarem uma cultura data-driven e incluírem a análise de dados em suas estratégias corporativas se tornarão irrelevantes. E gestores atentos estão criando e desenvolvendo suas equipes de Data Science. É um caminho sem volta, pois o volume de dados não vai parar de crescer e quem souber extrair valor dos dados estará a frente dos concorrentes. Em pouco tempo isso será requisito básico.

Com o aumento da demanda, estima-se que não haverá profissionais qualificados em número suficiente ainda por um bom tempo. Além disso, a Ciência de Dados veio para ficar. Pensando nisso, a DSA criou esse Guia de Boas Práticas em Ciência de Dados chamado **DSAKG**.

O **DSAKG** é um livro contendo as boas práticas em Ciência de Dados, resultado do trabalho dos profissionais da DSA e experiência capacitando mais de 900 mil alunos ao longo de mais de 8 anos.

Convidamos você a iniciar uma excelente jornada de aprendizagem durante a leitura desse extraordinário material.

Unidade V





Engenharia de Dados




Engenharia de Dados




O Que é Engenharia de Dados?

A Engenharia de Dados é a aplicação de técnicas de engenharia ao processo de aquisição, limpeza, transformação e armazenamento de dados, com o objetivo de torná-los mais acessíveis, confiáveis e úteis para análises e tomada de decisão.

A Engenharia de Dados engloba uma série de atividades, incluindo a modelagem de dados, integração de dados, segurança de dados, mineração de dados e sistemas de informação gerencial.



Hadoop e Engenharia de Dados




Como o Hadoop Pode Auxiliar Na Engenharia de Dados?

O Hadoop é um framework de código aberto que permite o armazenamento e processamento de grandes quantidades de dados de forma distribuída em clusters de computadores.

Ele é composto principalmente pelo Hadoop Distributed File System (HDFS), que é um sistema de arquivos distribuído que permite o armazenamento de grandes quantidades de dados em vários nós de computação, e pelo MapReduce, que é um modelo de programação para processamento em paralelo de grandes conjuntos de dados.

O Hadoop pode ser usado para ajudar na Engenharia de Dados de diversas maneiras. Por exemplo: ele pode ser usado para armazenar grandes quantidades de dados de forma eficiente e acessá-los rapidamente para análise.






Como o Hadoop Pode Auxiliar Na Engenharia de Dados?

O Hadoop também pode ser usado para processar grandes quantidades de dados de forma paralela, o que pode ser útil na limpeza e transformação de dados.


Além disso, o Hadoop pode ser integrado com outras ferramentas de análise de dados, como o **Apache Spark**, o **Apache Hive** e o **Apache HBase**, o que torna mais fácil realizar análises avançadas em grandes conjuntos de dados.

E o HDFS ainda pode ser usado na construção de Data Lakes.





Modos de Execução do Hadoop




Quais os Modos de Execução do Hadoop?

O Hadoop pode ser executado em dois modos principais:


- O **Modo Standalone** é o modo padrão de execução do Hadoop e é usado principalmente para fins de teste e demonstração. Nesse modo, o Hadoop é executado em um único nó de computação e não é necessário um cluster de computadores. É o modo mais fácil de instalar e configurar, mas não é adequado para o processamento de grandes quantidades de dados, pois ele não permite o uso de paralelismo.
- O **Modo Distribuído** é o modo mais comumente usado para fins de produção e é o modo mais adequado para o processamento de grandes quantidades de dados. Nesse modo, o Hadoop é executado em um cluster de computadores e permite o uso de paralelismo para processar grandes quantidades de dados de forma mais eficiente.

No entanto, o modo distribuído é mais complexo de instalar e configurar do que o modo standalone, pois requer a configuração de vários nós de computação e o gerenciamento do cluster.



Ecosystem Hadoop






Quais os Componentes do Ecosystema Hadoop?

O ecossistema Hadoop é composto por vários componentes que podem ser usados em conjunto ou de forma independente para armazenar, processar e analisar grandes quantidades de dados. Alguns dos componentes mais comuns do ecossistema Hadoop incluem:

- Hadoop Distributed File System (HDFS): um sistema de arquivos distribuído para armazenar grandes quantidades de dados em vários nós de computação.
- MapReduce: um modelo de programação para processamento em paralelo de grandes conjuntos de dados.
- Apache Hive: uma plataforma para análise de dados estruturados que permite aos usuários consultar grandes quantidades de dados usando a linguagem SQL.





Quais os Componentes do Ecosystema Hadoop?

- **Apache Spark:** um framework de processamento em paralelo de grandes conjuntos de dados que pode ser usado para análises em tempo real.
- **Apache Flume:** um sistema para coleta, armazenamento e transporte de grandes quantidades de dados em fluxo contínuo.
- **Apache NiFi:** uma ferramenta para transferir dados entre o Hadoop e diversos outros sistemas.

Esses são apenas alguns exemplos dos componentes que fazem parte do ecossistema Hadoop.

Existem muitos outros componentes disponíveis, cada um com suas próprias características e usos específicos.





Cluster



O Que é um Cluster?

Um cluster é um grupo de computadores ligados que trabalham juntos como uma única unidade, com o objetivo de realizar tarefas que exigem muitos recursos de processamento ou armazenamento.

Os clusters são geralmente usados para aumentar a capacidade de processamento ou para tornar os sistemas mais resistentes a falhas, permitindo que as tarefas sejam distribuídas entre vários computadores em vez de confiar em um único sistema.


Existem vários tipos de clusters, incluindo:

- ☐ Clusters de alta disponibilidade: São clusters projetados para garantir que os sistemas fiquem disponíveis o tempo todo, mesmo em caso de falhas. Eles podem incluir redundância de hardware e software para garantir que os serviços possam ser mantidos mesmo quando há problemas em algumas das máquinas.
- ☐ Clusters de computação em nuvem: São clusters que permitem que os usuários acessem recursos de computação remotamente, como se estivessem em uma nuvem. Isso pode ser útil para empresas que precisam acessar grandes quantidades de recursos de computação sem ter que investir em hardware próprio.




O Que é um Cluster?

- ❑ **Clusters de armazenamento de dados:** São clusters que são usados para armazenar grandes quantidades de dados de maneira distribuída, geralmente em vários discos. Eles podem ser usados para garantir a integridade dos dados, mesmo em caso de falhas, e para aumentar a velocidade de acesso aos dados.
- ❑ **Clusters de computação de alto desempenho:** São clusters que são projetados para realizar tarefas que exigem muitos recursos de processamento, como simulações científicas ou análises de dados em larga escala. Eles geralmente incluem muitos nós de computação interconectados para distribuir as tarefas entre eles e acelerar o tempo de processamento.
- ❑ **Clusters de virtualização:** São clusters que usam tecnologias de virtualização para dividir um único sistema físico em vários sistemas virtuais, cada um com sua própria configuração de hardware e software. Isso pode ser útil para aumentar a eficiência do uso do hardware e para facilitar a implantação de novos sistemas.




Cluster
Hadoop



Como Planejar Um Cluster Hadoop

Para planejar um cluster Hadoop é necessário considerar os seguintes passos:

- 1) Definir as necessidades de armazenamento e processamento: Determine quantos dados serão armazenados e qual o nível de processamento necessário para as tarefas do Hadoop.
- 2) Escolher os nós: Escolha os nós do cluster, levando em conta a capacidade de armazenamento e processamento de cada um.
- 3) Escolher o sistema operacional: Decida qual sistema operacional será usado no cluster. O Hadoop é compatível com vários sistemas operacionais, mas Linux é a escolha ideal na maioria dos casos.
- 4) Escolher a versão do Hadoop: Há várias versões do Hadoop disponíveis e uma versão deve ser escolhida.




Como Planejar Um Cluster Hadoop

- 1) Configurar as redes: Configure as redes do cluster, incluindo a rede de dados e a rede de administração.
- 2) Instalar e configurar os softwares: Instale e configure os softwares do Hadoop, incluindo o HDFS, o YARN e o MapReduce.
- 3) Testar e otimizar o cluster: Teste o cluster e otimize-o para obter o melhor desempenho possível.
- 4) Monitorar e manter: Implemente uma estratégia de monitoramento e manutenção para garantir que o cluster esteja funcionando corretamente e esteja sempre atualizado.



Mapreduce



O Que é Mapreduce?

MapReduce é um modelo de programação distribuída para processamento de grandes conjuntos de dados.

Ele foi desenvolvido pelo Google e é composto por dois passos principais: "Map" e "Reduce".

O passo "Map" é responsável por dividir o conjunto de dados em pequenas partes, que são processadas de forma paralela.

Já o passo "Reduce" reúne essas partes para produzir o resultado final.

O MapReduce é amplamente utilizado em sistemas de processamento distribuído, como o Hadoop, sendo a base de diversos outros softwares de processamento paralelo.



Recuperação de Falhas no Mapreduce



Como Funciona o Processo de Recuperação de Falhas no Mapreduce?

No MapReduce, a recuperação de falhas é geralmente implementada através de uma combinação de mecanismos de replicação e tolerância a falhas.


A replicação é usada para garantir que os dados sejam armazenados em múltiplos nós, de modo que, se um nó falhar, os dados ainda estejam disponíveis em outros nós.

A tolerância a falhas é alcançada através de vários mecanismos, incluindo:

Reexecução automática de tarefas falhas: Se uma tarefa falhar, o sistema irá automaticamente reexecutá-la em outro nó.

Rebalanceamento de carga: Se um nó falhar, a carga é redistribuída entre os nós restantes, para garantir que todas as tarefas possam ser concluídas.

Heartbeats: Os nós do sistema enviam periodicamente sinais de vida (heartbeats) para o nó mestre, de modo que, se um nó falhar, o nó mestre possa detectar e lidar com a falha.



ETL e
BIG DATA




Qual o Papel do ETL no Big Data?


ETL (Extraair, Transformar e Carregar) é um processo utilizado para movimentar dados de diferentes fontes para um local centralizado, como um data warehouse ou um data lake, para análise e processamento.

No contexto de Big Data, ETL é utilizado para coletar, limpar, transformar e carregar grandes volumes de dados de diversas fontes, como logs de aplicações, registros de transações e dados de sensores, para que possam ser processados e analisados usando ferramentas de análise de Big Data.

Em resumo, o papel do ETL no Big Data é preparar e mover os dados de forma que eles possam ser facilmente processados e analisados.



**Banco de
Dados**




Quais os Principais Bancos de Dados do Mercado?


Os principais sistemas gerenciadores de bancos de dados (SGBDs) do mercado incluem:

- ✓ **Oracle Database:** É um dos SGBDs mais populares e amplamente utilizado no mercado, com recursos avançados de segurança, disponibilidade e escalabilidade.
- ✓ **MySQL:** É um SGBD de código aberto amplamente utilizado para aplicativos web e aplicativos móveis.
- ✓ **Microsoft SQL Server:** É um SGBD comercial desenvolvido pela Microsoft, com recursos avançados de inteligência empresarial e análise de dados.
- ✓ **PostgreSQL:** É SGBD de código aberto altamente escalável e confiável, com recursos avançados de segurança e gerenciamento de dados.
- ✓ **MongoDB:** É um SGBD NoSQL projetado para lidar com grandes volumes de dados não estruturados e oferece escalabilidade e flexibilidade.





Ferramentas
ETL




Quais as principais ferramentas ETL do Mercado?


As principais ferramentas ETL no mercado incluem:

- ❖ Informatica PowerCenter
- ❖ IBM InfoSphere DataStage
- ❖ Oracle Data Integrator (ODI)
- ❖ Talend
- ❖ Microsoft SQL Server Integration Services (SSIS)
- ❖ SAP Data Services
- ❖ Pentaho Data Integration
- ❖ Alteryx
- ❖ AWS Glue
- ❖ Google Cloud Dataflow
- ❖ Apache NiFi
- ❖ Airbyte






Ambiente de
Banco de Dados



Como Devemos Preparar um Ambiente de Banco de Dados para Receber Big Data?

Existem algumas etapas importantes a serem seguidas ao preparar um ambiente de banco de dados para receber Big Data:

1. Escolha a tecnologia de armazenamento adequada: existem várias tecnologias de armazenamento que são adequadas para Big Data, como Hadoop, NoSQL e Relacional. Certifique-se de escolher a tecnologia que melhor atenda às suas necessidades.
2. Dimensionamento: é importante dimensionar o ambiente de armazenamento de acordo com o volume de dados que você espera armazenar e processar. Isso inclui dimensionar o hardware, a capacidade de armazenamento e a capacidade de processamento.
3. Escalabilidade: é importante que o ambiente de banco de dados seja escalável, para que possa crescer com a demanda.
4. Redundância: para garantir a disponibilidade dos dados, caso haja falhas no hardware ou no software.



Como Devemos Preparar um Ambiente de Banco de Dados para Receber Big Data?


5. **Garantia de desempenho:** é importante garantir que o sistema de armazenamento possa lidar com as altas taxas de ingestão de dados e alta velocidade de consulta. Isso pode incluir otimização de consultas, distribuição de dados e indexação.

6. **Monitoramento e manutenção:** é importante monitorar o ambiente de armazenamento regularmente para identificar problemas e garantir que ele esteja funcionando corretamente. Isso também inclui manutenção regular para garantir a integridade dos dados e prevenir problemas futuros.





Segurança em Engenharia de Dados




Por Que Segurança é Importante em Engenharia de Dados?

A segurança é importante na Engenharia de Dados porque os dados são uma parte valiosa e sensível das empresas.

Proteger os dados contra acesso não autorizado, vazamento, modificação ou destruição é essencial para garantir a privacidade e a confidencialidade dos clientes e a integridade dos negócios.

Além disso, as regulamentações de privacidade e de segurança de dados, como GDPR e LGPD, exigem que as empresas tomem medidas para proteger os dados pessoais.

A falta de segurança dos dados pode levar a sanções legais e danos à reputação da empresa.



Segurança Com Hadoop




Quais os Métodos de Autenticação e Segurança Num Sistema Hadoop?

Hadoop tem vários métodos de autenticação e segurança, incluindo:


- **Autenticação Kerberos:** Hadoop suporta autenticação baseada em Kerberos, que é uma técnica de autenticação baseada em senhas criptografadas.
- **Controle de Acesso Baseado em Papéis:** Hadoop permite controlar o acesso aos recursos de cluster através de políticas baseadas em papéis.
- **Criptografia de Dados:** Hadoop suporta a criptografia de dados em repouso e em trânsito para proteger os dados sensíveis.
- **Autorização:** O Hadoop usa o Apache Ranger para autorizar o acesso aos recursos de cluster, como tabelas Hive e arquivos HDFS.
- **Autenticação com Certificado Digital:** O Hadoop também pode ser configurado para usar certificados digitais para autenticar os usuários que acessam o cluster.





Hadoop x Spark






O Que Diferencia o Hadoop do Spark?

Apache Hadoop é um software de gerenciamento de dados distribuído e escalável que permite processar grandes conjuntos de dados usando uma arquitetura de cluster.

Ele inclui componentes como o HDFS (Hadoop Distributed File System) para armazenamento de dados e o MapReduce para processamento paralelo.

Apache Spark, por outro lado, é uma biblioteca de processamento de dados distribuído que oferece uma maneira mais rápida e fácil de trabalhar com grandes conjuntos de dados em comparação com o MapReduce do Hadoop.

O Spark permite processamento de dados em tempo real e análise interativa, além de suportar vários formatos de dados, incluindo estruturados e não estruturados. Spark é compatível com o Hadoop e pode ser executado no mesmo cluster do Hadoop.



Processamento de Bilhões de Registros



Como Processar Bilhões de Registros?

Existem várias maneiras de processar grandes volumes de dados, como bilhões de registros. Algumas das abordagens comuns incluem:

Distribuição: dividir os dados em vários nós de processamento e processá-los em paralelo. Isso pode ser feito com ferramentas de cluster, como Apache Hadoop ou Apache Spark.

Otimização de Armazenamento: usar banco de dados otimizados para grandes volumes de dados, como Apache Cassandra ou Google BigTable.

Stream Processing: processando dados enquanto eles são gerados, em vez de armazená-los e processá-los posteriormente. Isso pode ser feito com ferramentas como Apache Kafka ou Apache Storm.

Compressão: compactar os dados antes de armazená-los ou processá-los para reduzir o uso de armazenamento e aumentar a velocidade de processamento.



Como Processar Bilhões de Registros?

Usando um serviço de cloud computing como AWS Glue, Google Cloud Dataflow, ou Azure Data Factory para processar grandes volumes de dados.

É importante notar que a abordagem ideal dependerá do seu caso de uso específico e das ferramentas disponíveis.



Data Warehouse



O que é um Data Warehouse?

Um Data warehouse é um banco de dados projetado para armazenar grandes quantidades de dados históricos, geralmente de diversas fontes diferentes, para ser usado para análise e relatórios.

Ele é otimizado para consultas complexas e agregações de dados, e é geralmente usado em conjunto com ferramentas de Business Intelligence.

DWs (Data Warehouses) são muito relevantes na era do Big Data, pois eles fornecem uma maneira de armazenar e gerenciar grandes volumes de dados de diferentes fontes e fornecer consultas e relatórios analíticos.

Eles também fornecem uma camada de segurança e governança de dados para garantir que os dados estejam corretos e seguros.

Além disso, muitas empresas usam DWs em conjunto com tecnologias de Big Data, como Hadoop e Spark, para processar grandes volumes de dados e fornecer insights analíticos em tempo real.

Fim da Unidade V

