




DSAKG®

Guia de Conhecimentos em Ciência de Dados da Data Science Academy



Bem-Vindo(a)





ACADEMY, D.S. *E-book. Guia de Conhecimentos e Boas Práticas em Ciência de Dados da Data Science Academy.*
Brasília, 2024.

Versão 1.0.3

Copyright © 2024 Data Science Academy
Todos os direitos reservados.



www.datascienceacademy.com.br

Data Science Academy



Nossa maior satisfação é ver nossos alunos progredirem, com autonomia, inovação, criatividade e dinamismo, incorporando sempre novos conhecimentos, promovendo seu crescimento profissional e pessoal.

Nosso objetivo é que você aprenda de verdade e seja reconhecido no mercado de trabalho. Por isso, mais uma vez, a DSA avança na expansão e promoção do conhecimento, trazendo de forma pioneira um Programa Completo de **Certificação em Ciência de Dados** para várias carreiras e diferentes níveis.


Elaboramos um guia versátil, completo e inovador, que fará de você um profissional diferenciado e altamente recomendado para o mercado de Trabalho.

Onde quer que você esteja em sua jornada de aprendizagem, nós esperamos que você esteja sempre crescendo e renovando suas habilidades. **Siga em frente!**





Índice



Introdução


A Ciência de Dados já é uma realidade no Brasil. As empresas que não criarem uma cultura data-driven e incluírem a análise de dados em suas estratégias corporativas se tornarão irrelevantes. E gestores atentos estão criando e desenvolvendo suas equipes de Data Science. É um caminho sem volta, pois o volume de dados não vai parar de crescer e quem souber extrair valor dos dados estará a frente dos concorrentes. Em pouco tempo isso será requisito básico.

Com o aumento da demanda, estima-se que não haverá profissionais qualificados em número suficiente ainda por um bom tempo. Além disso, a Ciência de Dados veio para ficar. Pensando nisso, a DSA criou esse Guia de Boas Práticas em Ciência de Dados chamado **DSAKG**.

O **DSAKG** é um livro contendo as boas práticas em Ciência de Dados, resultado do trabalho dos profissionais da DSA e experiência capacitando mais de 900 mil alunos ao longo de mais de 8 anos.

Convidamos você a iniciar uma excelente jornada de aprendizagem durante a leitura desse extraordinário material.

Unidade II





Universo da Ciência de Dados





A Revolução dos Dados



A Revolução dos Dados

A revolução tecnológica trouxe a necessidade de coletar, processar, armazenar, analisar e compreender grandes volumes de dados de maneira significativa.

No entanto, o valor dos dados armazenados é zero, a menos que sejam convertidos em informação e usados para suportar a tomada de decisões.

A escala de volume, variedade e velocidade dos dados impõe novas demandas às organizações para descobrir rapidamente relacionamentos e padrões ocultos.

É aqui que as técnicas de Ciência de Dados provaram ser extremamente úteis e cada vez mais estão presentes nas atividades cotidianas de muitas funções empresariais e governamentais, seja na identificação de quais clientes provavelmente levarão a um aumento do lucro de uma empresa ou no mapeamento da pandemia de gripe usando mensagens de mídia social.

Dados, a matéria-prima da Ciência de Dados, é hoje um ativo empresarial.



A Revolução dos Dados

A Ciência de Dados é um conjunto de técnicas que extraem valor dos dados. Algumas das técnicas usadas em Ciência de Dados têm uma longa história e traçam suas raízes na Estatística Aplicada, Machine Learning, Visualização, Lógica e Ciência da Computação.

A maioria das tecnologias emergentes passa pelo que é chamado de “ciclo de hype”. Essa é uma maneira de comparar a quantidade de hipóteses ou exageros versus a produtividade gerada pela tecnologia emergente. Com a Ciência de Dados também temos esse ciclo de hype.

O ciclo tem três fases principais: pico de expectativa inflada, vale de desilusão e platô de produtividade.

A terceira fase refere-se à fase madura e geradora de valor de qualquer tecnologia. O ciclo de hype para a Ciência de Dados indica que ela está nessa fase madura. Isso implica que a Ciência de Dados parou de crescer ou atingiu um ponto de saturação? Não, pelo contrário.



A Revolução dos Dados

A Ciência de Dados cresceu além do escopo de suas aplicações iniciais em marketing e avançou para aplicações em finanças, saúde, governo, manufatura e praticamente qualquer outra área onde dados estiverem disponíveis.

Ou seja, estamos vivendo a verdadeira Revolução dos Dados. Com dados em abundância, capacidade computacional e técnicas de análise temos condições de transformar empresas, negócios e até mesmo mercados inteiros.

E com a grande quantidade de ferramentas open-source disponíveis para Ciência de Dados, a Revolução dos Dados está ao alcance de qualquer profissional, de qualquer empresa.

Entretanto, não pense que não há preço a pagar. Há sim. A quantidade de técnicas, além de toda Matemática, Estatística e tecnologias por trás da Ciência de Dados pode ser algo esmagador.

Mas é por isso que estamos aqui. Para compreender o Universo dos Dados e sua revolução.



Definindo Ciência de Dados



Definindo Ciência de Dados

A Ciência de Dados (Data Science) é uma coleção de técnicas usadas para extrair valor dos dados.

Tornou-se uma ferramenta essencial para qualquer organização que coleta, armazena e processa dados como parte de suas operações e tomada de decisão.

As técnicas de Ciência de Dados ajudam a encontrar padrões, conexões e relacionamentos úteis nos dados.

Sendo um termo da moda, há uma grande variedade de definições e critérios para o que constitui Ciência de Dados.

A Ciência de Dados também é comumente chamada de descoberta de conhecimento, aprendizado de máquina, análise preditiva e mineração de dados. No entanto, cada termo tem uma conotação ligeiramente diferente, dependendo do contexto. De fato, tudo isso faz parte do que chamamos de Ciência de Dados.





Definindo Ciência de Dados

Apesar do atual crescimento e popularidade, muitos métodos da Ciência de Dados têm décadas, senão séculos.

Os seres humanos sempre foram criaturas voltadas para o futuro e ciências preditivas são manifestações dessa curiosidade.

Então, quem usa e aplica Ciência de Dados atualmente? Quase todas as organizações e negócios. Se dados estiverem disponíveis, a Ciência de Dados pode ser utilizada.

O uso do termo Ciência em Ciência de Dados indica que os métodos são baseados em evidências e são construídos sobre conhecimento empírico, mais especificamente observações históricas.

À medida que a capacidade de coletar, armazenar e processar dados aumentou, de acordo com a Lei de Moore - o que implica que os recursos de hardware de computação dobram a cada dois anos - a Ciência de Dados encontrou aplicações crescentes em muitos campos diversos.



Definindo Ciência de Dados

Há apenas algumas décadas, a construção de um modelo de regressão linear levava diversas horas com um razoável volume de dados.

Mas a tecnologia evoluiu e percorreu um longo caminho.

Hoje, modelos sofisticados de aprendizado de máquina podem ser executados, envolvendo centenas de preditores com milhões de registros, em questão de alguns segundos em um laptop.

O processo envolvido na Ciência de dados, no entanto, não mudou desde os primeiros dias e provavelmente não mudará muito no futuro próximo.

Para obter resultados significativos de quaisquer dados, ainda é necessário um grande esforço de preparação, limpeza, depuração ou padronização dos dados, antes que os algoritmos de aprendizado possam começar a processá-los.

Mas o que pode mudar é a automação disponível para isso.





Definindo Ciência de Dados

Embora hoje esse processo seja iterativo e exija a conscientização dos analistas sobre as melhores práticas, em breve a automação inteligente poderá ser implantada.

Isso permitirá que o foco seja colocado no aspecto mais importante da Ciência de Dados: interpretar os resultados da análise para tomar decisões. Isso também aumentará o alcance da Ciência de Dados para um público mais amplo.

Quando se trata de técnicas de Ciência de Dados, existe um conjunto central de procedimentos e princípios que se deve dominar.

A grande maioria dos profissionais de Ciência de Dados hoje usa um punhado de técnicas muito poderosas para atingir seus objetivos: árvores de decisão, modelos de regressão, aprendizado profundo e clustering, por exemplo.

Mas a maior parte das atividades em Ciência de Dados pode ser realizada usando relativamente poucas técnicas.





Definindo Ciência de Dados

Escolher a melhor abordagem de Ciência de Dados para um projeto depende de muitos fatores: os dados que temos em mãos, o volume dos dados, o tipo de problema que estamos tentando resolver, a capacidade computacional disponível e, claro, o nível de conhecimento do profissional de dados.

Logo, haverá um grande conjunto de possibilidades, técnicas, procedimentos e ferramentas disponíveis.

Assim, valerá a pena aprender Ciência de Dados e seus métodos de forma sistemática e é isso que é abordado ao longo dos cursos da Data Science Academy e resumido neste livro.

Mas antes vamos compreender a relação entre Inteligência Artificial (IA), Machine Learning e Ciência de Dados.



IA, Machine Learning e Data Science



IA, Machine Learning e Data Science

Inteligência Artificial, Machine Learning e Ciência de Dados estão todos relacionados entre si. O que têm em comum? A matéria-prima, dados.

Os termos são frequentemente usados de forma intercambiável e confundidos uns com os outros na mídia popular e na comunicação empresarial. No entanto, todos esses três campos são distintos dependendo do contexto.

A Inteligência Artificial é dar às máquinas a capacidade de imitar o comportamento humano, particularmente as funções cognitivas.

Exemplos seriam: reconhecimento facial, direção automatizada, processamento de linguagem natural.

Em alguns casos, as máquinas excederam em muito as capacidades humanas (classificando milhares de imagens em segundos, por exemplo) e em outros casos mal arranhamos a superfície. Pelo menos ainda.



IA, Machine Learning e Data Science

Há uma grande variedade de técnicas que se enquadram na Inteligência Artificial: linguística, processamento de linguagem natural, ciência da decisão, visão computacional, robótica, planejamento, etc. E uma das técnicas empregadas em IA é exatamente o aprendizado de máquina.

Machine Learning (ou Aprendizado de Máquina) pode ser considerado um subcampo ou uma das ferramentas da Inteligência Artificial, cujo objetivo é fornecer às máquinas a capacidade de aprender com a experiência.

A experiência para máquinas vem na forma de dados. Os dados usados para ensinar as máquinas são chamados de dados de treinamento, dados históricos sobre determinado fenômeno ou evento.

Um programa de computador é um conjunto de instruções que transforma sinais de entrada em sinais de saída usando regras e relacionamentos predeterminados. Os algoritmos de aprendizado de máquina, também chamados de “aprendizes”, usam a entrada e a saída conhecidas (dados de treinamento) para descobrir um modelo para o programa que converte entrada em saída.



IA, Machine Learning e Data Science

Por exemplo, muitas organizações, como plataformas de mídia social, sites de avaliação ou fóruns, precisam moderar postagens e remover conteúdo abusivo. Como as máquinas podem ser ensinadas a automatizar a remoção de conteúdo abusivo?

As máquinas precisam receber exemplos de postagens abusivas e não abusivas com uma indicação clara de qual delas é abusiva. Os modelos generalizarão um padrão baseado em certas palavras ou sequências de palavras para concluir se a postagem geral é abusiva ou não.

O modelo pode assumir a forma de um conjunto de regras “se - então”. Depois que as regras ou o modelo são desenvolvidos, as máquinas podem começar a categorizar a disposição de quaisquer novas postagens.



IA, Machine Learning e Data Science

A Ciência de Dados, por sua vez, é a aplicação comercial de aprendizado de máquina, Inteligência Artificial e outros campos quantitativos, como estatística, visualização e matemática.

É um campo interdisciplinar que extrai valor dos dados. No contexto de como a Ciência de Dados é usada hoje, ela depende muito do aprendizado de máquina e às vezes é chamada de mineração de dados.


Aqui estão alguns exemplos de projetos de Ciência de Dados:

- Sistema de recomendação que pode recomendar produtos para um usuário específico.
- Modelo de alerta de fraude que detecta transações fraudulentas com cartão de crédito.
- Modelo capaz de prever se clientes irão desistir da assinatura de um serviço no próximo mês.
- Modelo capaz de prever a receita para o próximo trimestre.





Anatomia de Projetos de Ciência de Dados



Anatomia de Projetos de Ciência de Dados

Todo projeto de Ciência de Dados começa a definição de um problema de negócio.


Na sequência, trabalhamos com dados, que podem variar de uma simples matriz de algumas observações numéricas a uma matriz complexa de milhões de observações com milhares de variáveis.

A Ciência de Dados utiliza certos métodos computacionais especializados para descobrir estruturas significativas e úteis dentro de um conjunto de dados.

Sendo uma área multidisciplinar, a Ciência de Dados coexiste e está intimamente associada a várias áreas relacionadas, como sistemas de banco de dados, engenharia de dados, visualização, análise de dados, experimentação e inteligência de negócios (BI).

Logo, pode ser necessário empregar conhecimentos e técnicas de diferentes disciplinas. Vai depender do problema de negócio sendo resolvido, do volume e variedade dos dados e da capacidade computacional disponível.





Anatomia de Projetos de Ciência de Dados


Uma das tarefas do projeto pode ser a descoberta de conhecimento em bancos de dados, que é o processo não trivial de identificar padrões ou relacionamentos válidos, novos, potencialmente úteis e, em última análise, compreensíveis dentro de um conjunto de dados para tomar decisões importantes.

Uma outra tarefa de um projeto de Ciência de Dados pode envolver inferência e iteração de muitas hipóteses diferentes.


Um dos principais aspectos da Ciência de Dados é o processo de generalização de padrões de um conjunto de dados. A generalização deve ser válida não apenas para o conjunto de dados usado para observar o padrão, mas também para novos dados não vistos.

O objetivo final de um projeto de Ciência de Dados é encontrar conclusões potencialmente úteis que possam ser colocadas em prática pelos usuários de negócio da empresa.





Principais Técnicas Usadas em Ciência de Dados




Principais Técnicas Usadas em Ciência de Dados

Embora a Ciência de Dados abranja um amplo conjunto de técnicas, aplicações e disciplinas, existem algumas técnicas que serão usadas muito provavelmente em qualquer projeto de Ciência de Dados.

Aqui estão as 6 técnicas principais:

1- Estatística Descritiva: Calcular média, desvio padrão, correlação e outras estatísticas descritivas, quantificar a estrutura agregada de um conjunto de dados. Essas são informações essenciais para entender qualquer conjunto de dados, a estrutura dos dados e os relacionamentos dentro do conjunto de dados. Usamos Estatística Descritiva na fase de exploração do processo de Ciência de Dados.


2- Visualização Exploratória: O processo de expressar dados em coordenadas visuais permite que os usuários encontrem padrões e relacionamentos nos dados e compreendam grandes conjuntos de dados. A Visualização Exploratória é essencial nas etapas de pré e pós-processamento em Ciência de Dados.



Principais Técnicas Usadas em Ciência de Dados

3- Data Wrangling: Essa técnica é um conjunto de diversas tarefas, o que envolve limpeza dos dados, manipulação, processamento, engenharia de atributos, fatiamento dos dados e combinação de dados, visando a organização dos dados para análise. Essas tarefas podem ser realizadas em diversos momentos dentro de um projeto de Ciência de Dados.

4- Teste de Hipóteses: Quando os dados estiverem organizados, podemos formular hipóteses para validar uma suposição sobre a distribuição dos dados ou mesmo validar uma regra de negócio. Os dados são coletados para avaliar se uma hipótese tem evidências suficientes para ser apoiada ou não. Existem muitos tipos de testes estatísticos e eles têm uma ampla variedade de aplicações (por exemplo, testes A/B em marketing). Em geral, a Ciência de Dados é um processo onde muitas hipóteses são geradas e testadas com base em dados observacionais.



Principais Técnicas Usadas em Ciência de Dados

5- Engenharia de Dados: A engenharia de dados é o processo de obtenção, organização, montagem, armazenamento e distribuição de dados para análise e uso. Engenharia de banco de dados, armazenamento distribuído e estruturas de computação (por exemplo, Apache Hadoop, Spark, Kafka), computação paralela, transformação de extração e processamento de carregamento e armazenamento de dados constituem técnicas de engenharia de dados. A engenharia de dados ajuda a fornecer dados para algoritmos de aprendizado de máquina e alimentam os projetos de Ciência de Dados.

6- Business Analytics: Este é o processo de análise propriamente dito, que visa consultar os dados ou usar painéis ou visualizações para comunicar os fatos e tendências. Podemos usar SQL ou ferramentas de análise. Business Analytics é a entrega segura de informações para as funções certas e na distribuição de informações em escala. As tendências históricas geralmente são relatadas e as tendências futuras previstas. É aqui onde entregamos os resultados da Ciência de Dados.



Fim da Unidade II

