




# DSAKG®

## Guia de Conhecimentos em Ciência de Dados da Data Science Academy



**Bem-Vindo(a)**





**ACADEMY, D.S.** *E-book. Guia de Conhecimentos e Boas Práticas em Ciência de Dados da Data Science Academy.*  
**Brasília, 2024.**

**Versão 1.0.3**

**Copyright © 2024 Data Science Academy**  
**Todos os direitos reservados.**



**[www.datascienceacademy.com.br](http://www.datascienceacademy.com.br)**

# Data Science Academy



Nossa maior satisfação é ver nossos alunos progredirem, com autonomia, inovação, criatividade e dinamismo, incorporando sempre novos conhecimentos, promovendo seu crescimento profissional e pessoal.

Nosso objetivo é que você aprenda de verdade e seja reconhecido no mercado de trabalho. Por isso, mais uma vez, a DSA avança na expansão e promoção do conhecimento, trazendo de forma pioneira um Programa Completo de **Certificação em Ciência de Dados** para várias carreiras e diferentes níveis.


Elaboramos um guia versátil, completo e inovador, que fará de você um profissional diferenciado e altamente recomendado para o mercado de Trabalho.

Onde quer que você esteja em sua jornada de aprendizagem, nós esperamos que você esteja sempre crescendo e renovando suas habilidades. **Siga em frente!**





# Índice



# Introdução

---


A Ciência de Dados já é uma realidade no Brasil. As empresas que não criarem uma cultura data-driven e incluírem a análise de dados em suas estratégias corporativas se tornarão irrelevantes. E gestores atentos estão criando e desenvolvendo suas equipes de Data Science. É um caminho sem volta, pois o volume de dados não vai parar de crescer e quem souber extrair valor dos dados estará a frente dos concorrentes. Em pouco tempo isso será requisito básico.

Com o aumento da demanda, estima-se que não haverá profissionais qualificados em número suficiente ainda por um bom tempo. Além disso, a Ciência de Dados veio para ficar. Pensando nisso, a DSA criou esse Guia de Boas Práticas em Ciência de Dados chamado **DSAKG**.

O **DSAKG** é um livro contendo as boas práticas em Ciência de Dados, resultado do trabalho dos profissionais da DSA e experiência capacitando mais de 900 mil alunos ao longo de mais de 8 anos.

Convidamos você a iniciar uma excelente jornada de aprendizagem durante a leitura desse extraordinário material.

# Unidade III





# Boas Práticas





## O Processo Geral da Ciência de Dados



## O Processo Geral da Ciência de Dados

A descoberta metódica de relacionamentos e padrões úteis em dados é possibilitada por um conjunto de atividades iterativas conhecidas coletivamente como Processo de Ciência de Dados.

O processo padrão de Ciência de Dados envolve:

- (1) Entender o problema.
- (2) Preparar as amostras de dados.
- (3) Desenvolver um modelo.
- (4) Aplicar o modelo em um conjunto de dados para ver como o modelo pode funcionar no mundo real.
- (5) Implantação e manutenção dos modelos.

Ao longo dos anos de evolução das práticas de Ciência de Dados, diferentes estruturas para o processo foram apresentadas por vários órgãos acadêmicos e comerciais.





## O Processo Geral da Ciência de Dados

Uma das estruturas de processo de Ciência de Dados mais populares é o CRISP-DM, que é um acrônimo para Cross Industry Standard Process for Data Mining. Essa estrutura foi desenvolvida por um consórcio de empresas envolvidas em mineração de dados. O processo CRISP-DM é a estrutura mais amplamente adotada para o desenvolvimento de soluções de Ciência de Dados.

Um outra estrutura de processo de Ciência de Dados é o SEMMA, um acrônimo para Sample, Explore, Modify, Model, and Assess, desenvolvido pelo SAS Institute.


A estrutura apresentada neste módulo é sintetizada a partir de boas práticas de Ciência de Dados e com base nas estruturas mencionadas anteriormente.

Este módulo serve como um roteiro de alto nível para executar projetos de Ciência de Dados e discute os desafios enfrentados em cada etapa e as armadilhas a serem evitadas.



## O Processo Geral da Ciência de Dados

A imagem abaixo apresenta o Processo Geral da Ciência de Dados com base nas estruturas mencionadas, boas práticas do mercado e na experiência dos profissionais da Data Science Academy.





## O Processo Geral da Ciência de Dados

O Processo Geral da Ciência de Dados apresentado na figura anterior é um conjunto genérico de etapas que são independentes do tipo de problema de negócio, algoritmos e ferramentas de Ciência de Dados.

O objetivo fundamental de qualquer processo que envolva Ciência de Dados é resolver um problema de negócio. O problema em questão pode ser uma segmentação de clientes, uma previsão de padrões de compras ou uma simples exploração de dados.

O algoritmo de aprendizado usado para resolver a questão de negócios pode ser uma árvore de decisão, uma rede neural artificial ou um modelo de regressão linear.

A ferramenta de software para desenvolver e implementar o processo de Ciência de Dados pode ser: Linguagem Python, Linguagem R, RapidMiner, Weka, SAS, Oracle Data Miner, Orange, isso para citar apenas alguns exemplos.



Tudo Começa com o  
Objetivo



## Tudo Começa com o Objetivo

O processo de Ciência de Dados começa com uma necessidade de análise, uma pergunta ou um objetivo de negócio.

Este é possivelmente o passo mais importante no processo de Ciência de Dados.

Sem uma declaração bem definida do problema, é impossível encontrar o conjunto de dados correto e escolher o algoritmo adequado.

Como um processo iterativo, é comum voltar às definições sempre que os dados revelarem algo que não estava claro no início. Aqui estão algumas boas práticas para essa etapa do processo:

- 1- Defina claramente o objetivo junto com as áreas de negócio.
- 2- Descreva o problema e peça aprovação de gestores ou pessoas chave dentro da empresa.
- 3- Faça pesquisa complementar se não estiver compreendendo alguma definição do problema.



## Tudo Começa com o Objetivo

- 4- Use projetos anteriores como referência para ajudar a definir o problema de negócio.
- 5- Se muitas perguntas de negócio estiverem sendo feitas, você pode estar diante de vários projetos e não apenas um como pensado inicialmente.
- 6- Se não for possível compreender o problema claramente, uma exploração inicial em dados relacionados à definição do problema podem ajudar a ter uma ideia da real necessidade.
- 7- Erros na definição do problema vão impactar todas as etapas seguintes do processo.





## Processo de Negócio



## Processo de Negócio

O processo de Ciência de Dados revela padrões ocultos no conjunto de dados expondo relacionamentos entre atributos.

Mas o problema é que o processo revela (ou pode revelar) muitos padrões.

Os sinais falsos ou espúrios são um grande problema no processo de Ciência de Dados. Cabe ao Analista peneirar os padrões expostos e aceitar aqueles que são válidos e relevantes para a resposta da questão de negócio. Portanto, é essencial conhecer o assunto, o contexto e o processo de negócios que gera os dados. Aqui estão algumas boas práticas para essa etapa do processo:

1- Revise o processo de negócio que gerou o problema a ser resolvido. Por exemplo: se o objetivo é criar um modelo para detectar fraudes financeiras, é importante revisar o processo de finanças, revisar documentos, transações ou mesmo sistemas ligados ao processo. Se não compreender o processo, como você será capaz de identificar os relacionamentos nos dados ou mesmo uma anomalia quando se deparar com uma?



## Processo de Negócio

2- Muitas empresas não têm documentação sobre seus processos de negócio e cada processo está na mente dos profissionais de cada setor. Isso dificulta o trabalho e a melhor forma de lidar com isso é conversar com as pessoas e tentar documentar o processo. Não há fórmula mágica.

3- Valide a saída do processo de Ciência de Dados comparando com o resultado de um processo de negócio ou identificando como o resultado do seu trabalho realmente responde à pergunta de negócio.





# Dados



## Dados

Compreender como os dados são coletados, armazenados, transformados, descritos e usados é essencial para o processo de Ciência de Dados.

É preciso pesquisar todos os dados disponíveis para responder à pergunta de negócio e definir se novos dados precisam ser obtidos.

Há uma série de fatores a serem considerados: qualidade dos dados, quantidade de dados, disponibilidade de dados, lacunas nos dados, falta de dados (que obriga a mudança na questão do negócio), etc. O objetivo desta etapa é criar um conjunto de dados para responder à pergunta de negócio por meio do processo de Ciência de Dados.

Um modelo é tão bom quanto os dados usados para criá-lo. Aqui estão algumas boas práticas para essa etapa do processo:

1- Não são os dados que definem o problema. O problema é de que define os dados que serão usados. Tudo começa com o objetivo e não com os dados.





## Dados

2- Talvez o problema possa não ser respondido com os dados disponíveis. Nesse caso, ou adquirimos novos dados ou mudamos a definição do problema.

3- Dados podem estar disponíveis em bancos de dados transacionais, Data Warehouses, Data Lakes, arquivos pdf, planilhas ou páginas web. Pode ser necessário implementar um pipeline de captura, coleta, armazenamento e processamento dos dados antes de iniciar o processo de análise.


4- Dados raramente estarão limpos e prontos para uso. Sempre verifique a qualidade dos dados e aplique a limpeza necessária.

5- Dados podem ser combinados de diferentes fontes e isso traz desafios adicionais de qualidade e nesse caso os dados devem ser padronizados. Por exemplo: uma fonte de dados pode trazer o nome do estado como "São Paulo", enquanto outra fonte pode usar o termo como "SP". Uma das duas formas terá que ser usada e essa decisão depende do tipo de informação daquela variável.





# Exploração e Limpeza de Dados



## Exploração e Limpeza de Dados

A exploração de dados, também conhecida como análise exploratória de dados, fornece um conjunto de ferramentas simples para alcançar o entendimento básico dos dados.

As abordagens de exploração de dados envolvem estatísticas descritivas e visualização de dados, que podem expor a estrutura dos dados, a distribuição dos valores, a presença de valores extremos e destacar as inter-relações dentro do conjunto de dados.

Estatísticas descritivas como média, mediana, moda, desvio padrão e intervalo para cada atributo fornecem um resumo facilmente legível das principais características da distribuição de dados. Por outro lado, um gráfico visual de pontos de dados fornece uma compreensão instantânea de todos os pontos de dados condensados em um gráfico. Aqui estão algumas boas práticas para essa etapa do processo:

- 1- Comece a exploração dos dados buscando por problemas evidentes como valores ausentes, caracteres estranhos ou linhas duplicadas.



## Exploração e Limpeza de Dados

- 2- Calcule as estatísticas das variáveis numéricas e identifique a distribuição de cada variável.
- 3- Para as variáveis categóricas identifique as categorias e a proporção de registros de cada categoria. Categorias com baixa proporção podem ser eliminadas.
- 4- Faça análise univariada para cada variável individual e análise bivariada para as combinações de variáveis numéricas (por exemplo, gráfico de dispersão) e combinações de variáveis categóricas (por exemplo, tabela de contingência).
- 5- Identifique a variável alvo (se houver uma para seu problema de negócio).
- 6- Crie gráficos e tabelas para suportar suas análises. Cada elemento visual deve ser interpretado e a análise documentada.
- 7- Você provavelmente vai precisar aplicar algum tipo de limpeza antes, durante e após a análise exploratória. Documente cada mudança nos dados.



## Tratamento de Valores Ausentes



## Tratamento de Valores Ausentes

Um dos problemas de qualidade de dados mais comuns é que alguns registros têm valores de atributos ausentes.

Existem vários métodos de mitigação diferentes para lidar com esse problema, mas cada método tem prós e contras. A primeira etapa do gerenciamento de valores ausentes é entender a razão por trás da falta de valores. Aqui estão algumas boas práticas para essa etapa do processo:

1- Rastrear a linhagem de dados (proveniência) pode levar à identificação de problemas sistêmicos durante a captura de dados ou erros na transformação de dados. Antes de tratar os valores ausentes, tente compreender porque eles ocorreram.

2- A melhor forma de compreender porque os valores ausentes ocorreram é compreender o processo de coleta dos dados e a fonte (ou fontes) de dados.

3- O valor ausente pode ser substituído por uma variedade de dados artificiais para que o problema possa ser gerenciado com impacto marginal nas etapas posteriores do processo de Ciência de Dados.



## Tratamento de Valores Ausentes

4- O tratamento de valores ausentes sempre vai provocar alguma alteração nos dados e uma das suas metas deve ser gerar o menor impacto possível.

5- Não há uma técnica ideal para tratar valores ausentes e sempre vai depender de como os dados estão organizados. Uma alternativa mais segura é remover as linhas com valores ausentes. Mas se isso reduzir demasiadamente o volume de dados, outras opções devem ser consideradas.

6- Colunas com 30% ou mais de valores ausentes podem ser descartadas.

7- Para colunas numéricas usamos imputação, preenchendo valores ausentes com uma estatística como a média ou a mediana.

8- Para variáveis categóricas usamos imputação, aplicando o preenchimento com a moda (categoria mais comum) ou com algum outro valor determinado.

# Fim da Unidade III

